

TER : JADE

16/06/2026

Justice Algorithmique des
Élections

Etudiants : Rabehi Milhane
Djennad Mahdi

Tuteur : Rambaud Romain –
Bligny Caroline

Sommaire : Système d'Intégration Automatisée des Abstracts (Projet JADE)

1. INTRODUCTION ET ARCHITECTURE SYSTEME	2
1.A) CONTEXTE DU PROJET JADE : JUSTICE ALGORITHMIQUE DES ÉLECTIONS	3
1.B) OBJECTIF TECHNIQUE : AUTOMATISATION DU PIPELINE D'EXTRACTION ET D'INTEGRATION DES RESUMES JURIDIQUES (ABSTRACTS)	3
1.C) SCHEMA DIRECTEUR MASTER : FLUX DE DONNEES DES SOURCES VERS LA CIBLE FINALE.....	3
2. GUIDE D'ARCHITECTURE DES DONNEES ET MODELISATION (VOLET SQL).....	4
2.A) AUDIT DES SOURCES : ANALYSE DES FORMATS HETEROGENES	4
2.B) STRATEGIE DE STAGING : MISE EN ŒUVRE DE LA ZONE DE TRANSIT	4
2.C) MODELISATION RELATIONNELLE : INTEGRATION SANS ALTERATION	4
3. LE PIPELINE ETL ET LE CONTROLE QUALITE (VOLET PYTHON).....	5
3.A) EXTRACTION, PARSING ET NETTOYAGE.....	5
3.B) LE "FILTRE AVANT-GARDE" (CIBLAGE METIER AN / SEN).....	5
3.C) SYSTEME D'AUDIT ET ENTONNOIR DE TRAITEMENT	5
4. DATA SCIENCE, STATISTIQUES ET INTELLIGENCE ARTIFICIELLE (NLP)	6
4.A) ANALYSE STATISTIQUE DES ATTENDUS (REPNSES AUX KPIS METIERS)	6
4.B) MODELISATION PREDICTIVE : LE PIPELINE NLP (NATURAL LANGUAGE PROCESSING)	7
4.C) VECTORISATION ET MODELISATION PREDICTIVE.....	7
4.D) ENTRAINEMENT DU MODELE ET PREVENTION DU "DATA LEAKAGE"	7
4.E) RESULTATS ET MATRICE DE CONFUSION	8
5. ARCHITECTURE LOGICIELLE ET GUIDE D'EXPLOITATION (PLATEFORME JADE)	8
5.A) STRUCTURATION ET INGENIERIE DU PROJET	8
5.B) DUALITE DES ENVIRONNEMENTS : PRODUCTION VS DIFFUSION SCIENTIFIQUE	9
5.C) GUIDE UTILISATEUR : LANCEMENT ET UTILISATION DU DASHBOARD	9
5.D) LES FONCTIONNALITES DU TABLEAU DE BORD (DASHBOARD).....	9
6. COORDINATION, METHODOLOGIE ET BILAN DU PROJET.....	10
6.A) METHODOLOGIE ET OUTILS DE COORDINATION	10
6.B) SYNERGIE ET REPARTITION DES ROLES.....	10
6.C) BILAN HORAIRE : ANALYSE DU PREVISIONNEL VS REEL.....	10
6.D) PERENNISATION DU PROJET ET TRANSMISSION	11
6.E) CONCLUSION ET PERSPECTIVES.....	12
7. ANNEXE	13

Sommaire : table des matières image

FIGURE 1 : DIAGRAMME DE FLUX DE DONNEES (DFD) DU PIPELINE ETL JADE ILLUSTRANT L'EXTRACTION, LA TRANSFORMATION (QUALITE VIA REGEX) ET LE CHARGEMENT DANS POSTGRESQL.....	3
FIGURE 2 : BASE DE DONNEES FINALE JADE	5
FIGURE 3 : ENTONNOIR DE TRAITEMENT DES DONNEES JADE. SUR UN VOLUME INITIAL MASSIF DE PLUS DE 25 000 ABSTRACTS BRUTS, LE PIPELINE ISOLE LES CONTENTIEUX AN/SEN ET ECARTE LES ANOMALIES, ABOUTISSANT A L'INTEGRATION DE 8 956 DOSSIERS QUALIFIES ET PRETS POUR L'ANALYSE	6
FIGURE 4 : PIPELINE DE TRAITEMENT DU LANGAGE NATUREL (NLP) APPLIQUE AUX DECISIONS DE JUSTICE, DU PRETRAITEMENT A LA RESTITUTION.	7
FIGURE 5 : MATRICE DE CONFUSION REALISE SUR JUPYTER NOTEBOOK	8
FIGURE 6 : PAGE D'ACCUEIL STREAMLIT	10
FIGURE 7 : DIAGRAMME DE GANTT FINAL DETAILLANT LE VOLUME HORAIRE EFFECTIF (270H/ETUDIANT) ET LA REPARTITION PAR TACHE.	11
FIGURE 8 : FICHIER DE DOCUMENTATION POUR LA PERENNITE DU PROJET (DOCUMENTATION PROJET JADE EN MARKDOWN)....	12

1. Introduction et architecture système

1.a) Contexte du projet JADE : Justice Algorithmique des Élections

Le projet JADE (Justice Algorithmique des Élections) est un projet interdisciplinaire associant le Centre de Recherche Juridique (CRJ) et le Laboratoire Jean Kuntzmann (LJK). Son objectif est d'étudier le contentieux électoral à partir des décisions du Conseil constitutionnel et des données électorales déjà présentes dans la base JADE. Avant notre intervention, la base de données contenait principalement les résultats électoraux et les métadonnées des décisions de justice. Les abstracts juridiques, qui résument le raisonnement des juges, existaient dans plusieurs fichiers JSON et Excel mais n'étaient pas intégrés à la base PostgreSQL. L'objectif du projet était donc d'intégrer ces données, d'améliorer leur organisation et de préparer leur exploitation pour l'analyse statistique et l'intelligence artificielle.

1.b) Objectif technique : Automatisation du pipeline d'extraction et d'intégration des résumés juridiques (Abstracts)

Afin d'automatiser l'intégration des abstracts dans la base JADE, nous avons développé un pipeline ETL complet en Python.

Ce pipeline permet :

- D'importer les données JSON et Excel.
- De charger les données dans une zone de staging.
- D'effectuer des contrôles qualité.
- De filtrer les données relatives aux contentieux électoraux (AN et SEN).
- D'intégrer les données validées dans les tables finales.
- De générer automatiquement les vues analytiques utilisées pour les futures exploitations.

1.c) Schéma Directeur Master : Flux de données des sources vers la cible finale

Le projet JADE repose sur une architecture de traitement automatisée permettant d'intégrer différentes sources de données juridiques dans une base PostgreSQL unifiée. Les données proviennent de plusieurs fichiers JSON et Excel contenant les abstracts, les rubriques, les décisions ainsi que les types de décisions. Ces données sont d'abord chargées dans une zone de staging (_raw), puis soumises à des contrôles qualité avant leur intégration dans les tables finales. Les données validées alimentent ensuite des vues analytiques permettant leur exploitation par les chercheurs, les outils statistiques et les futurs modules d'intelligence artificielle.





Figure 1 : Diagramme de flux de données (DFD) du pipeline ETL JADE illustrant l'extraction, la transformation (qualité via Regex) et le chargement dans PostgreSQL.

2. Guide d'Architecture des Données et Modélisation (Volet SQL)

2.a) Audit des sources : Analyse des formats hétérogènes


Le projet s'appuie sur plusieurs sources de données initialement déconnectées. Les principales sources exploitées sont :

- Abstracts-2023-01-12.json : contenant les résumés juridiques.
- Rubriques-2023-01-12.json : contenant la hiérarchie des thématiques juridiques.
- Extraction table decisionset.xlsx : contenant les informations relatives aux décisions.
- Type_sous_type.xlsx : contenant les catégories juridiques.
- La base historique JADE existante (restaurée à partir d'un dump PostgreSQL).



2.b) Stratégie de Staging : Mise en œuvre de la zone de transit

Afin d'éviter la corruption de la base de production par l'intégration directe de données brutes, une zone de transit (Area Staging) a été mise en place au sein de PostgreSQL. Les fichiers sont d'abord importés dans des tables dédiées (abstracts_raw, rubriques_raw, decisions_raw). Ces tables servent de point d'entrée au pipeline ETL. Une fois chargées, les données sont soumises à de stricts contrôles qualité avant d'être transférées vers les tables finales, facilitant la maintenance et la traçabilité des erreurs.



2.c) Modélisation Relationnelle : Intégration sans altération

L'une des contraintes majeures du projet était de relier les nouvelles données juridiques aux décisions déjà présentes dans la base historique sans en altérer le cœur. La nouvelle implémentation repose sur une conception en étoile respectant les principes de la troisième forme normale (3NF) :

- La table **abstracts** stocke le contenu textuel enrichi des décisions. Elle est reliée à la table pivot **public.decision** par une jointure forte basée sur les attributs **decision.numero** et **abstracts.reference_officielle**, qui constituent respectivement la clé de référence de la décision et son identifiant officiel dans la nouvelle structure. Cette correspondance garantit l'unicité du lien entre les données historiques et les nouveaux contenus juridiques, tout en assurant l'intégrité référentielle entre les deux ensembles de données.
- La table **rubriques** agit comme une table de dimension autonome permettant de structurer les abstracts selon une classification juridique hiérarchique. Chaque abstract est rattaché à une rubrique via une clé étrangère, ce qui facilite la catégorisation des décisions et évite la redondance des informations textuelles dans la base.




Figure 2 : Base de données finale JADE

3. Le Pipeline ETL et le Contrôle Qualité (Volet Python)

3.a) Extraction, Parsing et Nettoyage

Le cœur du traitement automatisé a été développé en Python (via les bibliothèques Pandas et SQLAlchemy). Une fois les données brutes extraites dans la zone de *Staging*, une phase de *parsing* (analyse syntaxique) est réalisée. Des expressions régulières (Regex) ont été implémentées pour corriger les incohérences de saisie, standardiser les encodages et, surtout, normaliser les références juridiques. Par exemple, une chaîne brute comme "DÉCISION N° 2022-123 AN" est nettoyée pour devenir l'identifiant strict "2022-123", garantissant ainsi une correspondance parfaite avec la base historique.

3.b) Le "Filtre Avant-Garde" (Ciblage Métier AN / SEN)

Le cahier des charges imposait de se concentrer exclusivement sur le contentieux électoral parlementaire. Pour ce faire, nous avons programmé un filtre strict dès l'entrée du pipeline :

- Le script analyse la référence brute de chaque abstract. S'il ne détecte ni la mention "AN" (Assemblée Nationale) ni "SEN" (Sénat), le dossier (ex: contentieux QPC ou référendums) est silencieusement ignoré.
- Ce tri automatisé permet d'alléger la base de données et de ne conserver que les données pertinentes pour le périmètre de la recherche.

3.c) Système d'Audit et Entonnoir de Traitement

Afin de garantir la fiabilité du système (zéro crash), un mécanisme de gestion des rejets a été développé de bout en bout. Chaque abstract passe par plusieurs points de contrôle :

1. **Vérification textuelle** : Rejet si le texte de l'abstract est vide ou trop court (moins de 10 caractères).
2. **Vérification thématique** : Rejet si la rubrique juridique associée ne fait pas partie du contentieux électoral (famille 8).
3. **Vérification d'intégrité** : Rejet si la référence est "orpheline" (c'est-à-dire si la décision correspondante n'existe pas dans le fichier Excel des décisions fourni).

Les anomalies détectées ne bloquent pas le programme : elles sont isolées et insérées dans une table SQL de monitoring (abstracts_rejets), avec journalisation détaillée des erreurs (Logs).




Figure 3 : Entonnoir de traitement des données JADE. Sur un volume initial massif de plus de 25 000 abstracts bruts, le pipeline isole les contentieux AN/SEN et écarte les anomalies, aboutissant à l'intégration de 8 956 dossiers qualifiés et prêts pour l'analyse

4. Data Science, Statistiques et Intelligence Artificielle (NLP)

Le travail de nettoyage massif effectué par notre pipeline ETL n'était pas une fin en soi, mais une condition préalable indispensable pour l'analyse par Intelligence Artificielle. Le dossier analytics/rapport_statistiques.ipynb (Jupyter Notebook) contient nos expérimentations en apprentissage automatique.

4.a) Analyse Statistique des Attendus (Réponses aux KPIs métiers)

Afin de répondre aux interrogations juridiques, plusieurs scripts d'analyse de données (via pandas et seaborn) ont été exécutés sur la base unifiée :

- **Densité de l'information (Objectif 4)** : Un algorithme a calculé le ratio entre la longueur d'un abstract et le texte intégral de la décision. La moyenne globale s'établit à 9.5%. Une analyse croisée a permis de classer les thèmes juridiques selon leur densité (ex: les contentieux liés à l'"Absence de dépôt" produisent les abstracts les plus denses en information).
- **Impact de l'écart de voix (Objectif 3)** : Une sous-analyse s'est concentrée sur les élections très serrées (moins de 500 voix d'écart). Les données quantitatives prouvent que lorsque l'écart est infime (< 50 voix), les thèmes de "Propagande" et d'"Absence de dépôt" sont les griefs les plus fréquemment invoqués par les requérants.
- **Évolution de la complexité (Objectif 2)** : Une modélisation temporelle (depuis 1958) a superposé le nombre d'affaires jugées et le volume d'abstracts produits. Ce double axe

permet aux chercheurs de visualiser mathématiquement la "complexité juridique" et l'inflation normative d'une époque donnée.

4.b) Modélisation Prédicative : Le Pipeline NLP (Natural Language Processing)

Afin d'extraire la connaissance juridique des abstracts, le texte brut a subi une série de transformations pour être compréhensible par la machine :

- **Nettoyage et Normalisation** : Suppression de la ponctuation, des caractères spéciaux et passage en minuscules.
- **Tokenisation et Lemmatisation** : Découpage des phrases en mots (tokens) et réduction à leur racine linguistique (ex: "élections" -> "élection").
- **Filtrage** : Suppression des mots vides (stopwords) et application d'un dictionnaire juridique spécifique pour conserver les termes porteurs de sens.




Figure 4 : Pipeline de traitement du langage naturel (NLP) appliqué aux décisions de justice, du prétraitement à la restitution.

4.c) Vectorisation et Modélisation Prédicative

Le texte nettoyé a ensuite été vectorisé (transformé en matrice numérique) à l'aide de la méthode **TF-IDF** (Term Frequency-Inverse Document Frequency), qui valorise les mots statistiquement importants dans le corpus. Ce modèle numérique a alimenté un algorithme de classification supervisée (Régression Logistique) dont l'objectif était d'apprendre à prédire la décision finale du juge (Annulation, Rejet, Inéligibilité) en lisant uniquement les abstracts.

4.d) Entraînement du Modèle et Prévention du "Data Leakage"

L'apprentissage s'est fait de manière supervisée à l'aide d'un algorithme de **Régression Logistique**. Une attention particulière a été portée à la prévention du phénomène de "Data Leakage" (fuite de données) : la base a été strictement scindée en données d'entraînement (80%) et données de test (20%). Le modèle a appris à associer des signatures sémantiques (les mots de l'abstract) à une solution juridique (la décision), sans jamais avoir accès à la variable cible durant son évaluation.

4.e) Résultats et Matrice de Confusion

Les résultats de notre modèle d'apprentissage sont très concluants. Évalué sur le jeu de données de test (des affaires totalement inconnues de l'algorithme), **l'IA a prédit la bonne solution dans 90,5 % des cas.**

La matrice de confusion met en évidence que les rejets et les inéligibilités sont parfaitement identifiés par l'algorithme. Cela confirme de manière empirique que la sémantique utilisée par les juges dans la rédaction des principes juridiques contient une signature formelle suffisante pour anticiper le verdict.




Figure 5 : Matrice de confusion réalisé sur Jupyter Notebook

5. Architecture Logicielle et Guide d'Exploitation (Plateforme JADE)

5.a) Structuration et Ingénierie du Projet

Afin de garantir la maintenabilité et la clarté du projet, le code source a été organisé selon les standards professionnels du développement logiciel. L'arborescence sépare rigoureusement la donnée, les requêtes SQL, l'algorithmique Python et la restitution analytique :

- Le dossier data/ stocke les sources brutes isolées.
- Le dossier sql/ externalise l'ensemble des requêtes (11 fichiers distincts pour la création des tables, l'insertion et les vues).
- Le dossier src/ contient le cœur du pipeline ETL développé en Programmation Orientée Objet (POO).
- Le dossier tests/ assure la qualité du code via des tests unitaires automatisés (Pytest).

5.b) Dualité des Environnements : Production vs Diffusion Scientifique

Pour répondre aux besoins des différents acteurs du projet, le système a été scindé en deux environnements distincts :

1. **L'Environnement de Production** : Réservé aux administrateurs de la base de données. Il nécessite PostgreSQL et exécute le pipeline complet via la commande :

```
python -m src.implementation_abstrats.run_pipeline
```

2. L'Environnement de Diffusion (Dossier Jade_portable/) : Conçu spécifiquement pour les chercheurs en droit. Il s'agit d'une version autonome de l'application qui ne nécessite aucune base de données (elle consomme un export CSV figé jade_export.csv) ni installation technique complexe.

5.c) Guide Utilisateur : Lancement et Utilisation du Dashboard

La plateforme d'analyse (Dashboard) a été développée sous la technologie Streamlit. Pour lancer l'application en tant qu'utilisateur final :

- Sous environnement Windows, double-cliquez sur le fichier « Lancer_JADE.bat ». Ce script vérifie automatiquement la présence de Python, installe les dépendances allégées requises et ouvre l'interface dans le navigateur web.
- Sous environnement Mac ou Linux, l'exécution du fichier « Lancer_JADE.sh » réalise la même procédure.

Une fois l'interface chargée, le chercheur dispose d'un explorateur de décisions interactif. Il peut filtrer la jurisprudence par juridiction (Assemblée Nationale ou Sénat), par période temporelle, ou par thématique juridique. Un module de recherche lexicale plein texte permet également d'isoler rapidement les dossiers traitant d'un moyen de droit précis (ex: "diffamation", "fraude électorale").

5.d) Les Fonctionnalités du Tableau de Bord (Dashboard)

Une fois l'interface chargée, le chercheur dispose d'une série de modules interactifs, alimentés par les données filtrées. Un bandeau latéral permanent permet de restreindre l'analyse par juridiction (Assemblée Nationale ou Sénat), par période temporelle (ex: 1958-2024), ou via une recherche lexicale ciblée.

L'application est structurée autour de plusieurs onglets analytiques :

- **Modélisation Temporelle** : Un graphique à double axe permettant de visualiser la corrélation entre le volume d'affaires jugées et la quantité de principes dictés par le juge au fil du temps (mesure de l'inflation jurisprudentielle).
- **Dossiers Documentaires** : Un explorateur hiérarchique permettant de reconstituer l'arborescence complète du raisonnement juridique d'une affaire spécifique, classée selon la numérotation officielle.
- **Analyse Croisée des Grieffs** : Une matrice de contingence (heatmap) mettant en évidence les probabilités d'aboutissement des requêtes en fonction du moyen de droit invoqué.
- **Densité Macro-Décisions** : Une distribution graphique descendante (sunburst) illustrant la ventilation des décisions majeures en catégories de contentieux.
- **Détection des Singularités (IA)** : Un algorithme d'audit traquant les déviations statistiques (outliers), isolant les affaires où la solution prononcée est atypique par rapport à la jurisprudence habituelle (fréquence < 3%).
- **Simulateur d'Inférence** : Un outil d'estimation du risque d'annulation basé sur le traitement sémantique des conclusions et pondéré par l'écart de voix du scrutin.




Figure 6 : Page d'accueil streamLit

6. Coordination, Méthodologie et Bilan du Projet

6.a) Méthodologie et Outils de Coordination

La réussite de ce projet interdisciplinaire (associant le droit et l'informatique) a nécessité une gestion de projet rigoureuse. Nous avons opté pour une **approche itérative** fonctionnant par cycles courts (sprints) : extraction des données, puis modélisation SQL, puis développement de la couche IA et analytique. La coordination a été assurée via :

- **Des points de synchronisation** : Une réunion de pilotage hebdomadaire d'une heure avec notre tutrice pour valider les choix techniques et l'adéquation au besoin juridique.
- **Des restitutions interdisciplinaires** : Des présentations régulières de l'état d'avancement à l'ensemble des équipes de recherche.
- **Un environnement de travail centralisé** : L'utilisation du dépôt GitLab de l'UGA a permis le versioning strict du code et a facilité le travail asynchrone du binôme.

6.b) Synergie et Répartition des Rôles

Pour optimiser notre efficacité, nous avons scindé les responsabilités selon nos expertises, tout en mutualisant les tâches analytiques (Data Science) et la rédaction des livrables :

- **Mahdi Djennad (Lead Developer Python)** : En charge du développement des algorithmes d'extraction (Parser), du nettoyage complexe des textes bruts (Expressions régulières) et de la mise en place des tests unitaires du code source.
- **Milhane Rabehi (Data Architect)** : En charge de la refonte et de l'optimisation de la base relationnelle PostgreSQL, de l'architecture globale du pipeline ETL et du développement des mécanismes de contrôle qualité (Data Quality).

6.c) Bilan Horaire : Analyse du Prévisionnel vs Réel

Le projet a représenté un volume global de **270 heures de travail par étudiant**. Le suivi de notre diagramme de Gantt a mis en évidence des réajustements nécessaires face à la réalité du terrain. Si la modélisation de la base de données relationnelle a été plus rapide que prévue (terminée en environ 35h au lieu des 55h estimées), la phase d'*Automatisation Python & Parsing* a requis un investissement massif (près de 150h). La très grande hétérogénéité des résumés juridiques et les nombreux cas particuliers ont exigé le développement d'expressions régulières beaucoup plus complexes qu'anticipé pour garantir une donnée finale parfaitement propre.

TÂCHE	EFFECTIF	Temps effectué (h) Milhane	Temps effectué (h) MAHDI	DÉBUT	FIN
Base de données relationnelle JADE		100	35	08/12/2025	30/04/2026
Analyse du schéma relationnel existant (UGA/IDEX)	Milhane, Mahdi	15	5	08/12/2025	20/12/2025
Modélisation des tables pour les "Abstracts"	Milhane	35	5	20/12/2025	05/01/2026
Création du script SQL (Tables/Index)	Milhane, Mahdi	15	10	05/01/2026	15/01/2026
Optimisation de la base pour le texte	Milhane	10	5	10/01/2026	20/01/2026
Externalisation et optimisation SQL	Milhane	10	0	05/01/2026	30/04/2026
Securisation et configuration centralisée	Milhane, Mahdi	15	10	01/02/2026	01/03/2026
Création de couches analytique (Vues)	Milhane	15	0	15/03/2026	30/04/2026
Automatisation Python & Parsing		90	150	21/01/2026	31/05/2026
Script de récupération des abstracts	Mahdi	10	30	21/01/2026	10/02/2026
Développement du parser (Regex/Text)	Mahdi, Milhane	15	55	11/02/2026	25/03/2026
Script de nettoyage des données	Mahdi	15	15	26/03/2026	10/04/2026
Module d'insertion SQL automatique	Mahdi, Milhane	15	25	11/04/2026	20/04/2026
Refactorisation et programmation orientée objet (POO)	Mahdi, Milhane	20	25	01/05/2026	25/05/2026
Orchestration du pipeline ETL	Milhane	15	0	07/05/2026	25/05/2026
Conteneurisation de l'application (Docker)	Mahdi	0	15	15/05/2026	31/05/2026
Test de qualité des données		15	35	21/04/2026	31/05/2026
Tests d'intégrité (Double saisie/Script)	Mahdi, Milhane	5	15	21/04/2026	10/05/2026
Debugging et robustesse du code	Mahdi, Milhane	10	10	11/05/2026	20/05/2026
Mise en place des tests unitaires automatisées	Mahdi	0	10	11/05/2026	31/05/2026
Systèmes d'audit et de journalisation	Mahdi	0	10	11/05/2026	31/05/2026
Analytiques & Data science		25	15	17/05/2026	15/06/2026
Développement du dashboard interactif	Milhane, Mahdi	10	15	17/05/2026	15/06/2026
Modélisation statistique et Machine learning	Milhane	15	0	17/05/2026	15/06/2026
Livrables techniques		40	35	21/05/2026	15/06/2026
Documentation technique du code Git	Mahdi, Milhane	10	20	21/05/2026	01/06/2026
Rapport final (Cahier des charges final)	Milhane	25	10	01/06/2026	10/06/2026
Support de soutenance (Oral)	Milhane, Mahdi	5	5	10/06/2026	15/06/2026
Configuration de l'environnement de développement	Mahdi	5	10	21/05/2026	15/06/2026
		270	270		

Figure 7 : Diagramme de Gantt final détaillant le volume horaire effectif (270h/étudiant) et la répartition par tâche.

6.d) Pérennisation du Projet et Transmission

Le projet JADE a été conçu pour durer et évoluer sans notre intervention. Sa transmission aux futures équipes de recherche repose sur trois piliers :

1. **Documentation** : La rédaction de guides structurés permet à un nouveau développeur de comprendre le rôle de chaque script en moins de 5 minutes.
2. **Standardisation** : La normalisation de l'architecture, combinée aux fichiers .env et requirements.txt, garantit la reproductibilité absolue de l'environnement Python sur n'importe quelle machine.
3. **Maintenance** : L'externalisation de toutes les requêtes SQL dans des fichiers dédiés et l'orchestration via un script maître automatisé facilitent l'ajout de nouvelles années électorales sans jamais avoir à modifier le code moteur de l'application.



Figure 8 : Fichier de documentation pour la pérennité du projet (Documentation projet JADE en markdown)

6.e) Conclusion et Perspectives

Ce Travail d'Étude et de Recherche a permis d'édifier une architecture robuste, transformant une base de données métadonnées en une plateforme d'intelligence juridique exploitable. À court terme, ce système permettra l'intégration facile de nouvelles juridictions. À moyen terme, l'outil analytique pourra intégrer des modèles de langage (LLMs type BERT) spécialisés en droit français pour affiner la justice algorithmique. JADE offre d'ores et déjà de nouvelles perspectives de recherche, notamment en croisant la complexité du contentieux avec la géographie électorale du pays.

7. Annexe

Annexe A : Architecture Technique et Inventaire des Fichiers Sources

Afin de garantir la reproductibilité du projet, l'arborescence du code a été structurée selon les standards professionnels :

```
JADE_ABSTRATS/  
├── .venv/                               # Environnement virtuel isolé (ignorer dans Git)  
├── .env                                # Variables sécurisées (Identifiants BDD, version PostgreSQL)  
├── requirements.txt                     # Liste des dépendances (pandas, psycpg2, streamlit, py)  
├── analytics/                           # Dossier pour l'analyse et la visualisation de données  
│   ├── app.py                          # Tableau de bord interactif Streamlit (Dashboard)  
│   └── rapport_statistiquesV2.ipynb    # Notebook Jupyter (Machine Learning & Stats)  
├── data/                               # Dossier contenant les données du projet  
│   ├── raw/                            # Fichiers sources bruts originaux  
│   │   ├── abstrats-2023-01-12.json  
│   │   ├── extraction table decisionset.xlsx  
│   │   ├── rubriques-2023-01-12.json  
│   │   └── type sous type.xlsx  
│   └── 202605jade.dump                 # Dump historique de la base de données  
├── docs/                              # Documentation et gestion de projet  
├── logs/                               # Dossier des journaux d'exécution (ex: qualite_donnees.  
├── sql/                                # Toutes les requêtes SQL externalisées (11 fichiers)  
├── src/                                # Code source principal (Python)  
│   ├── admin/                          # Scripts d'administration manuelle  
│   ├── config/                         # Configuration globale du projet (ex: settings.py)  
│   └── implementation_abstrats/        # Scripts du pipeline ETL (Classes héritées et sécurisées  
├── tests/                              # Tests unitaires (Assurance Qualité du code via pytest)  
├── Jade_portable/                      # Dossier de distribution autonome (Prêt à être zippé pou  
│   ├── Lancer_JADE.bat                 # Lanceur automatisé Windows  
│   ├── Lancer_JADE.sh                  # Lanceur automatisé Mac / Linux  
│   ├── app.py                          # Application Streamlit autonome  
│   ├── requirements.txt                 # Dépendances allégées pour les utilisateurs finaux  
│   └── data/                           #  
│       └── jade_export.csv              # Copie figée de la base de données
```


Annexe B : Architecture de la base de données sur PostgreSQL

Voici une présentation de la base de données JADE sur postgresSQL :

Tables (25)	
> abstrats	> grief38
> abstrats_rejets	> nuance
> appartenance	> raw_abstrats
> candidat	> raw_decisions
> corr_nuance	> raw_rubriques
> decision	> raw_types
> decision_analyse	> resultat
> decision_detail	> resultat_candidat
> decision_griefs38	> resultat_tour
> decisions_raw	> rubriques
> departement	> rubriques_raw
> election	> subdivision
	> types_raw


Annexe C : Mécanique de l'ETL



Voici comment l'ETL fonctionne du début à la fin :




Annexe D : Différents tableaux réalisés sur Jupyter notebook

Évolution du contentieux : Volume d'affaires vs Complexité Juridique





Cartographie Sémantique (Thèmes vs Solutions du juge)



--- DÉTECTION DES PARADOXES JURIDIQUES ---

L'algorithme a scanné toute la base et détecté 25 combinaisons paradoxales (Thème vs Décision).

PARADOXE DÉTECTÉ : [Propagande]

Résulte en 'annulation-puis-inéligibilité' dans seulement 0.2% des cas (1 affaire(s) trouvée(s)).


reference_officielle	ecart_voix	abstract_text
3702 2021-5726/5728AN	266.0	Il appartient au juge de l'élection de vérifier si des manœuvres ont été susceptibles de tromper les électeurs sur la réalité de l'investiture des candidats par les partis politiques. L'existence d'un soutien du candidat par ce parti politique, s'est ajoutée celle créée sur l'identité même de ce candidat, en raison de l'utilisation du nom « Jean de BOURBON » vote. Or, le démenti apporté, la veille du premier tour de scrutin en fin de journée, par le parti « La République en marche » sur le réseau social « Twitter » n'a pas, compte tenu de la diffusion limitée de ce message, permis de donner à l'absence d'investiture de ce candidat par le parti une publicité suffisante avant la tenue du scrutin pour prévenir une telle confusion. Dans les circonstances de l'espèce, la manœuvre commise par ce candidat a, compte tenu des 449 suffrages qu'il a obtenus et du faible écart de 266 voix ayant séparé le candidat arrivé en première position de la candidate arrivée en deuxième position au premier tour, été de nature à altérer la sincérité du scrutin.

PARADOXE DÉTECTÉ : [Rejet sans instruction contradictoire préalable]


Résulte en 'annulation' dans seulement 0.3% des cas (1 affaire(s) trouvée(s)).

reference_officielle	ecart_voix	abstract_text
636 2004-3381/3396SEN	NaN	Est irrecevable une requête qui se borne à des allégations d'ordre général et ne soulève aucun grief précis pouvant être utilement invoqué pour contester des opérations électorales.

Matrice de Confusion de l'IA (NLP)



Annexe E : Différentes pages de dashboard streamlit



Éléments de Filtrage

Moteur de recherche lexicale

Ex: distribution tardive, tracts, ém.

Segment temporel

1958 — 2024

Juridiction d'origine

Assemblée Natio... x

Sénat x

Catégories thématiques (Top 50)

Choose options

JADE v2.1 • Module Scientifique de Haute Jurisprudence Électorale

Affaires Multi-Griefs3 383

Principes Dicités (Abstracts)8 825

Élections Annulées92

Écart Médian1021 voix

Modélisation Temporelle

Dossiers Documentaires

Analyse Croisée des Griefs

Densité Macro-Décisions

Détection des Singularités (IA)

Simulateur d'Inference

Consultation des Attenus Relatifs aux Contentieux

Note d'analyse : Cette vue restitue l'architecture complète du raisonnement juridictionnel. Elle permet d'observer comment les différents moyens soulevés par les requérants ont été examinés, hiérarchisés puis retenus ou écartés par le juge électoral.

Sélectionner ou saisir une référence officielle d'affaire :

Affaire n° 73-685 — (39 abstrat(s) invoqué(s))

Juridiction compétente :Assemblée Nationale

ANNÉE DE L'ÉLECTION1973

SOLUTION PRONONCÉERejet

ÉCART DE SUFFRAGES265

Arborescence Textuelle du Raisonnement Juridique

§ 8.1.1.3.3.1 — Vote par correspondance

CONSIDÉRANT / ABSTRAT #300758

L'admission au vote par correspondance prononcée pour le premier tour est valable pour le second quand bien même la justification produite ne ferait état de la date du premier tour.

Éléments de Filtrage

Moteur de recherche lexicale

Ex: distribution tardive, tracts, ém.

Segment temporel

1958 — 2024

Juridiction d'origine

Assemblée Natio... x

Sénat x

Catégories thématiques (Top 50)

Choose options

JADE v2.1 • Module Scientifique de Haute Jurisprudence Électorale

Affaires Multi-Griefs3 383

Principes Dicités (Abstracts)8 825

Élections Annulées92

Écart Médian1021 voix

Modélisation Temporelle

Dossiers Documentaires

Analyse Croisée des Griefs


Densité Macro-Décisions

Détection des Singularités (IA)

Simulateur d'Inference

Probabilités Conditionnelles d'Aboutissement des Requêtes

Note d'analyse : Cette matrice mesure la relation statistique entre les griefs invoqués et les solutions rendues. Plus une cellule présente une intensité élevée, plus la combinaison « moyen juridique → décision » apparaît fréquemment dans la jurisprudence observée.



Éléments de Filtrage

Moteur de recherche lexicale

Ex: distribution tardive, tracts, ém.

Segment temporel

1958 — 2024

Juridiction d'origine

Assemblée Natio... x

Sénat x

Catégories thématiques (Top 50)

Choose options

JADE v2.1 • Module Scientifique de Haute Jurisprudence Électorale

Affaires Multi-Griefs3 383

Principes Dicités (Abstracts)8 825

Élections Annulées92

Écart Médian1021 voix

Modélisation Temporelle

Dossiers Documentaires

Analyse Croisée des Griefs


Densité Macro-Décisions

Détection des Singularités (IA)

Simulateur d'Inference

Distribution Descendante des Catégories de Contentieux

Note d'analyse : Cette représentation hiérarchique met en évidence la structure globale du contentieux électoral. Elle permet d'identifier quels griefs alimentent majoritairement chaque type de décision et de mesurer leur poids relatif dans l'activité juridictionnelle.



Éléments de Filtrage

Moteur de recherche lexicale

Ex: distribution tardive, tracts, ém.

Segment temporel

19582024

Juridiction d'origine

Assemblée Natio...

×

Sénat

×

Catégories thématiques (Top 50)

Choose options

JADE v2.1 • Module Scientifique de Haute Jurisprudence Électorale

Affaires Multi-Griefs

3 383

Principes Dicités (Abstracts)

8 825

Élections Annulées

92

Écart Médian

1021 voix

Modélisation Temporelle

Dossiers Documentaires

Analyse Croisée des Griefs

Densité Macro-Décisions

Détection des Singularités (IA)

Simulateur d'Inférence

Traque des Déviations Statistiques et Outliers Documentaires

Note d'analyse : Cet algorithme identifie les couples « grief → solution » dont la fréquence est statistiquement marginale au sein de la jurisprudence. Ces singularités peuvent révéler un revirement, une circonstance exceptionnelle ou une appréciation atypique du juge.

Analyse en cours : 18 couples paradoxaux isolés dans le périmètre actuel.

Sélectionner un couple jurisprudentiel divergent à inspecter :

Grief : [Absence de don ou d'avantage] → Solution : [Inéligibilité] (Atypique : 2.7% des décisions)

Affaires associées à cette divergence

reference_officielle	annee	solution	ecart_voix
518 2002-3029		2003 pas-d-ineligibilite	687
1908 2013-4793		2013 pas-d-ineligibilite	7114
7882 93-1898		1993 pas-d-ineligibilite	1405

Pièces et attendus des dossiers audités (Analyse doctrinale directe)

Examen des attendus textuels du dossier n° 2002-3029

Éléments de Filtrage

Moteur de recherche lexicale

Ex: distribution tardive, tracts, ém.

Segment temporel

19582024

Juridiction d'origine

Assemblée Natio...

×

Sénat

×

Catégories thématiques (Top 50)

Choose options

JADE v2.1 • Module Scientifique de Haute Jurisprudence Électorale

Affaires Multi-Griefs

3 383

Principes Dicités (Abstracts)

8 825

Élections Annulées

92

Écart Médian

1021 voix

Modélisation Temporelle

Dossiers Documentaires

Analyse Croisée des Griefs

Densité Macro-Décisions

Détection des Singularités (IA)

Simulateur d'Inférence

Estimation du Risque d'Annulation du Scrutin Électoral

Note d'analyse : Cet indice combine l'analyse lexicale des griefs invoqués et l'écart de suffrages observé. Il vise à estimer le niveau théorique de vulnérabilité du scrutin au regard des critères habituellement mobilisés par le juge électoral.

Saisir les conclusions factuelles de la réclamation ou de la requête :

Exemple : Considérant que des tracts diffamatoires contenant des éléments nouveaux ont été distribués de manière très tardive la veille du scrutin sans possibilité de démenti utile...

Paramètres Numériques

Écart de suffrages constaté :

75

Type de scrutin électoral :

Législative (AN)

Calculer le Risque d'Annulation

Travaux de recherche et d'études – RABEHI Milhane, DJENNAD Mahdi

19