

TUTEUR : ROMAIN RAMBAUD (PROFESSEUR DE DROIT PUBLIC, CRJ)
RÉFÉRENTE : CAROLINE BLIGNY (INFORMATICIENNE, CHEFFE DE PROJET LJK)

1

CADRE : PROJET TER – MASTER MIASHS – 2025-2026
DJENNAD MAHDI, RABEHI MILHANE

Justice Algorithmique des Elections (JADE)

Analyse et traitement automatique du contenu électoral par
l'Intelligence Artificielle



SOMMAIRE

Introduction & Cadrage du
projet JADE

Gestion de projet et
méthodologie

Refonte de l'architecture &
Modélisation des données

Le pipeline ETL : Nettoyage et
Pérennisation

Intelligence artificielle : NLP et
Analyse prédictive

La plateforme LegalTech
(Dashboard Interactive)

Bilan & Démonstration en direct

Introduction & Cadrage

INTRODUCTION : LE PROJET JADE

Cadre scientifique :


- ❑ Projet ANR & IDEX (Interdisciplinaire).
- ❑ Collaboration : Droit (CRJ) ↔ Info/Maths (LJK).

L'état de l'art (L'existant) :

- ❑ Base PostgreSQL opérationnelle.
- ❑ Données : Résultats électoraux + les décisions de justice en Métadonnées (Dates, Rejets).

L'ambition

- ❑ Dépasse l'analyse des résultats pour analyser le raisonnement du juge (Justice prédictive).



DE LA DONNÉE MUETTE A L'INFORMATION EXPLOITABLE – LE CONSTAT

❑ Une base de données "muette" :

PostgreSQL contient les résultats électoraux, mais le raisonnement juridique du juge est absent.

❑ Des données éparpillées :

Les Abstracts (résumés juridiques) sont isolés dans des fichiers JSON et Excel hétérogènes.

❑ Le verrou technique :

Aucun lien automatisé avec la base PostgreSQL.

Décision n° 2013-4831 AN
du 22 mars 2013

 **Abstract**
1 élément

 **Commentaire**
Pdf 169.8 Ko

 **Version PDF de la décision**
Pdf 20.78 Ko

 **Lien stable de la décision**

LE CONSEIL CONSTITUTIONNEL,

Vu la décision en date du 23 janvier 2013, enregistrée au secrétariat général du Conseil constitutionnel le 5 février 2013 sous le numéro 2013-4831 AN, par laquelle la Commission nationale des comptes de campagne et des financements politiques, constatant le non-dépôt de son compte de campagne dans le délai légal, saisit le Conseil constitutionnel de la situation de M. Hervé DROUOT, demeurant à Besançon (Doubs), candidat aux élections qui se sont déroulées en juin 2012 dans la 1ère circonscription du département du Doubs pour l'élection d'un député à l'Assemblée nationale ;


Vu les observations présentées par M. DROUOT, enregistrées au secrétariat général du Conseil constitutionnel le 26 février 2013 ;

DE LA DONNEE MUETTE A L'INFORMATION EXPLOITABLE - NOTRE MISSION



Extraire & Nettoyer :

Développer un pipeline ETL robuste en Python pour traiter ces milliers de fichiers.



Modéliser & Pérenniser :

Refondre l'architecture SQL pour lier intelligemment les décisions à leurs abstracts.




Valoriser (Data Science) :

Préparer ce nouveau corpus propre pour l'analyse par Intelligence Artificielle (NLP).

Gestion de projet & Méthodologie

METHODOLOGIE & COORDINATION



Approche Itérative :

Développement par "sprints" successifs (Extraction, puis SQL, puis IA).




Points de synchronisation :

Réunion de pilotage Hebdomadaire (1h) avec notre tuteur pour valider les choix techniques et juridiques.



Environnement de travail :

Utilisation de GitLab pour le versioning du code, permettant un travail asynchrone efficace du binôme.



Restitutions interdisciplinaires :

Présentations régulières de l'avancement du projet à l'ensemble des équipes pour s'assurer de l'adéquation avec le besoin métier.

SYNERGIE & RÉPARTITION DES RÔLES

Mahdi Djennad : Lead Developer Python

- ❑ Développement des algorithmes d'extraction (Parser).
- ❑ Nettoyage complexe des textes (Expressions régulières).
 - ❑ Tests unitaires du code source.

Milhane Rabehi : Data Architect

- ❑ Refonte et optimisation de la base relationnelle (PostgreSQL).
 - ❑ Architecture globale du pipeline ETL.
 - ❑ Contrôles de la qualité des données (Data Quality).


Tâches communes

- ❑ Analytics & Data Science.
- ❑ Rédaction des livrables techniques.

Architecture & BDD

DIAGRAMME DE FLUX DE DONNÉES (DFD)

De données juridiques brutes à l'analyse et aux insights



❑ **Sécurisation :**

Mise en place d'une zone Staging (raw_) pour isoler l'ingestion.

❑ **Optimisation (3NF) :**

Normalisation de la base (ex: table rubriques dédiée).

❑ **Vues Métier :**


Reconstitution dynamique des données pour soulager l'application.

LA MODELISATION RELATIONNELLE

Contraintes métier : Zéro modification du cœur de la base existante


Normalisation (3NF) : Extraction des thèmes juridiques dans une table de dimension autonome (rubriques) pour éviter la redondance massive de texte et optimiser les performances

Conception satellite : Création de la table principale abstracts reliée aux décisions par une jointure forte



PIPELINE ETL

LA MECANIQUE DE L'ETL (L'ARCHITECTURE DU FLUX)




❑ **Ingestion Python :**
Utilisation de pandas et SQLAlchemy pour lire les fichiers JSON et Excel massifs.

❑ **Zone de Staging (Le Sas) :**
Les données atterrissent d'abord dans des tables _raw. Rien ne touche la production sans avoir été vérifié.

❑ **Gestion des Rejets :**
Création d'une table abstracts_rejets pour isoler les anomalies sans faire planter le pipeline.

ENTONNOIR DE TRAITEMENT DES DONNÉES



❑ **Volume initial massif :**
Traitement de plus de 25 600 résumés (Abstracts) et de milliers de décisions.

❑ **Ciblage strict (AN / SEN) :**
Application de règles métier via des expressions régulières (Regex) en Python pour ne conserver que les contentieux parlementaires pertinents.

❑ **Résultat qualitatif :**
Une base finale de 8 956 données validées, propres, et prêtes pour l'analyse par Intelligence Artificielle.

LE PIPELINE ETL : ROBUSTESSE ET QUALITE LOGICIELLE

```
class DatabaseManager:
    def __init__(self):
        self.conn = None
    def connect(self):
```

DÉMARRAGE DU PROCESSUS DE QUALITÉ
Bilan Qualité : 8956 validés | 0 rejets

```
ogs > qualite_donnees.log
1 2026-05-06 13:07:41,640 | ERROR | date_decision | ID 999999 | La date de décision est manquante.
2 2026-05-06 13:54:53,221 | ERROR | date_decision | ID 999999 | La date de décision est manquante.
3 2026-05-06 13:55:24,290 | ERROR | date_decision | ID 999999 | La date de décision est manquante.
4 2026-05-11 12:33:24,650 | ERROR | date_decision | ID 999999 | La date de décision est manquante.
```

Query Query History Scratch Pad x

1 SELECT * FROM abstracts_rejet;

Data Output Messages Notifications

id_rejet	id_abstract_raw	decision_id_raw	motif_rejet	donnees_brutes	date_rejet
[PK] integer	integer	integer	character varying (255)	jsonb	timestamp with

❑ Code Modulaire (POO) :

- Orchestration automatisée via `run_pipeline.py`.
- Connexions PostgreSQL sécurisées et centralisées (`DatabaseManager`).

❑ Qualité & Traçabilité (Zéro Crash) :

- Isolement automatique des données aberrantes (ex: ID 999999 ou dates manquantes) grâce au script `data_quality.py`.
- Génération de fichiers d'audit détaillés et alimentation d'une table SQL de rejets.


❑ Assurance Qualité (TDD) :

- Validation continue de la robustesse des expressions régulières à l'aide de tests unitaires (`pytest`).

INTELLIGENCE ARTIFICIELLE

DU TEXTE BRUT A LA DONNEE EXPLOITABLE (NLP)

💡 **Objectif :** Extraire la connaissance juridique utile des décisions de justice pour aider les chercheurs à comprendre les tendances et les raisonnements.



TECHNOLOGIES & OUTILS



Python
Langage principal



scikit-learn
Machine Learning



Streamlit
Interface web



PostgreSQL
Base de données



pandas
Manipulation de données



Calcul numérique





SHAP
Explicabilité des modèles



Visualisations

Matrice de Confusion de l'IA (NLP)



Objectifs Analytiques et Besoins Métier (Projet JADE)

1. Filtrage multicritère et requêtes croisées

Fonctionnalité : Création d'un système de tri avancé dans la base de données.

Objectif : Permettre la sélection d'abstracts spécifiques pour identifier les décisions de justice qui y sont associées (ex: "Dans quelles décisions retrouve-t-on cette problématique").

2. Analyse temporelle et longitudinale

Fonctionnalité : Suivi chronologique des abstracts.

Objectif : Rendre possible la comparaison des décisions associées à un même type d'abstract sur des périodes distinctes. L'enjeu est notamment d'observer l'évolution de la rédaction.

3. Corrélation avec les solutions juridiques et les données électorales

Fonctionnalité : Interconnexion entre l'analyse textuelle et les résultats des scrutins.

Objectif : Lier les abstracts à la solution finale de la décision (annulation, rejet, etc.) et aux métadonnées électorales, en particulier les écarts de voix. Cela permettra de dé.

4. Cartographie sémantique et statistiques descriptives

Fonctionnalité : Création d'une table analytique dédiée à l'extraction de statistiques.

Objectifs :

Cartographie : Croiser les différentes catégories d'abstracts entre elles pour détecter les redondances et visualiser leurs regroupements au sein d'une même décision.


Métriques : Générer des statistiques descriptives précises (par exemple : calculer le pourcentage de texte que représente l'abstract par rapport au volume total de la décision).

Prédiction de l'IA

L'IA prédit la bonne solution dans 90.5% des cas (sur des affaires 100% inconnues) !

DASHBOARD

RESTITUTION : IMMERSION DANS L'APPLICATION JADE



BILAN

PERRENNISATION DU PROJET ET TRANSMISSION

 Documentation	 Standardisation	 Maintenance
Documentation structurée sous forme de guides.	Projet versionné sur Git avec une structure normalisée. Fichiers requirements.txt et .env	Externalisation des requêtes SQL dans des fichiers dédiés et automatisation via un script maître
Qu'un nouveau développeur comprenne le rôle de chaque fichier source en 5 minutes.	Garantir la reproductibilité de l'environnement Python sur n'importe quelle machine.	Cela facilite l'ajout de nouvelles données électorales sans modifier le moteur de l'application.

BILAN DE PROJET : DÉFIS ET PERFORMANCE - PREVISIONNEL

TÂCHE	EFFECTIF	TEMPS EFFECTUÉ (H)/ MILHANE	TEMPS EFFECTUÉ (H)/ MAHDI	DÉBUT	FIN
Base de données relationnelle JADE		110	55	08/12/2025	20/01/2026
Analyse du schéma relationnel existant (UGA/IDEX)	Milhane, Mahdi	15	15	08/12/2025	20/12/2025
Modélisation des tables pour les "Abstracts"	Milhane	45	10	20/12/2025	05/01/2026
Création du script SQL (Tables/Index)	Milhane, Mahdi	30	20	05/01/2026	15/01/2026
Optimisation de la base pour le texte	Milhane	20	10	10/01/2026	20/01/2026
Automatisation Python & Parsing		85	145	21/01/2026	20/04/2026
Script de récupération des abstracts	Mahdi	10	30	21/01/2026	10/02/2026
Développement du parser (Regex/Text)	Mahdi, Milhane	35	75	11/02/2026	25/03/2026
Script de nettoyage des données	Mahdi	15	15	26/03/2026	10/04/2026
Module d'insertion SQL automatique	Mahdi, Milhane	25	25	11/04/2026	20/04/2026
Test de qualité des données		25	35	21/04/2026	20/05/2026
Tests d'intégrité (Double saisie/Script)	Mahdi, Milhane	15	25	21/04/2026	10/05/2026
Debugging et robustesse du code	Mahdi	10	10	11/05/2026	20/05/2026
Livrables techniques		50	35	21/05/2026	15/06/2026
Documentation technique du code Git	Mahdi, Milhane	10	20	21/05/2026	01/06/2026
Rapport final (Cahier des charges final)	Milhane	35	10	01/06/2026	10/06/2026
Support de soutenance (Oral)	Milhane, Mahdi	5	5	10/06/2026	15/06/2026
		270	270		

BILAN DE PROJET : DÉFIS ET PERFORMANCE - REEL

TÂCHE	EFFECTUE	Temps effectué (h)/ Milhane	Temps effectué (h)/ MAHDI	DÉBUT	FIN
Base de données relationnelle JADE		100	35	08/12/2025	30/04/2026
Analyse du schéma relationnel existant (UGA/INDEX)	Milhane, Mahdi	15	5	08/12/2025	20/12/2025
Modélisation des tables pour les "Abstracts"	Milhane	35	5	20/12/2025	05/01/2026
Création du script SQL (Tables/Index)	Milhane, Mahdi	15	10	05/01/2026	15/01/2026
Optimisation de la base pour le texte	Milhane	10	5	10/01/2026	20/01/2026
Externalisation et optimisation SQL	Milhane	10	0	05/01/2026	30/04/2026
Securisation et configuration centralisée	Milhane, Mahdi	15	10	01/02/2026	01/03/2026
Création de couches analytique (Vues)	Milhane	15	0	15/03/2026	30/04/2026
Automatisation Python & Parsing		90	150	21/01/2026	31/05/2026
Script de récupération des abstracts	Mahdi	10	30	21/01/2026	10/02/2026
Développement du parser (Regex/Text)	Mahdi, Milhane	15	55	11/02/2026	25/03/2026
Script de nettoyage des données	Mahdi	15	15	26/03/2026	10/04/2026
Module d'insertion SQL automatique	Mahdi, Milhane	15	25	11/04/2026	20/04/2026
Refactorisation et programmation orientée objet (POO)	Mahdi, Milhane	20	25	01/05/2026	25/05/2026
Orchestration du pipeline ETL	Milhane	15	0	07/05/2026	25/05/2026
Conteneurisation de l'application (Docker)	Mahdi	0	15	15/05/2026	31/05/2026
Test de qualité des données		15	35	21/04/2026	31/05/2026
Tests d'intégrité (Double saisie/Script)	Mahdi, Milhane	5	15	21/04/2026	10/05/2026
Debugging et robustesse du code	Mahdi, Milhane	10	10	11/05/2026	20/05/2026
Mise en place des tests unitaires automatisées	Mahdi	0	10	11/05/2026	31/05/2026
Systèmes d'audit et de journalisation	Mahdi	0	10	11/05/2026	31/05/2026
Analytiques & Data science		25	15	17/05/2026	15/06/2026
Développement du dashboard interactif	Milhane, Mahdi	10	15	17/05/2026	15/06/2026
Modélisation statistique et Machine learning	Milhane	15	0	17/05/2026	15/06/2026
Livrables techniques		40	35	21/05/2026	15/06/2026
Documentation technique du code Git	Mahdi, Milhane	10	20	21/05/2026	01/06/2026
Rapport final (Cahier des charges final)	Milhane	25	10	01/06/2026	10/06/2026
Support de soutenance (Oral)	Milhane, Mahdi	5	5	10/06/2026	15/06/2026
Configuration de l'environnement de développement	Mahdi	5	10	21/05/2026	15/06/2026
		270	270		

CONCLUSION ET PERSPECTIVES



A court terme : Intégration de nouveaux jeux de données juridiques (autres juridictions).



À moyen terme (l'IA) : Passage à des modèles de langages plus avancées (ex: LLMs de type BERT ou équivalents français) pour aller plus loin que la régression logistique.



Ouverture de recherche : JADE devient un outil pour les chercheurs, permettant d'identifier de nouvelles corrélations entre géographie et contentieux électoral

Merci de votre écoute !
Des questions ?